# LANGKAH – LANGKAH MENGUBAH HIMPUNAN DATA WDBC, ABALONE DAN BANK MARKETING SERTA MEMBAGINYA MENJADI DATA TRAINING DAN TESTING

disusun untuk memenuhi tugas mata kuliah Data Mining

oleh:

### Khairul Umam Albi 2008107010072



## JURUSAN INFORMATIKA FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM UNIVERSITAS SYIAH KUALA DARUSSALAM, BANDA ACEH

#### A. Dataset WDBC

- Tools yang digunakan adalah WEKA explorer
- 1. Langkah-langkah untuk memisahkan data WDBC
  - Buka WEKA Explorer dan buka file WDBC.arff.
  - Kemudian pada bagian filter pilih Randomize pada package weka => filters => unsupervised=>instance => Randomize.
- Tanpa melakukan konfigurasi tambahan maka dataset tersebut telah teracak.
- Selanjutnya Kembali ke bagian filter pilih RemovePercentage pada package weka => filters =>unsupervised => instance => RemovePercentage.
- Pada bagian tersebut mengantikan presentase menjadi 80.0 untuk data testing maka data terhapus sebanyak 80 persen.
- Selanjutnya tekan apply dan simpan data tersebut dengan menekan save as di WEKA menjadi wdbc-testing.arrf.
- Kembali ke halaman utama weka dan klik undo, selanjutnya ganti nilai invertSelection menjadi True, dengan percentage masih sama maka data tersimpan sebanyak 80 persen.
- 2. Uraikan hasil klasifikasi yang diperoleh.

Proses klasifikasi menggunakan Classifier IBk (Lazy/KNN) dengan k=3, k=5, k=7, k=9,dan k=11 serta pembobotan dalam voting penentuan class adalah distanceWeighting =Weight by 1/distance.

a. Supplied test set WDBC-testing.arff pada k = 3

```
=== Summary ===
Correctly Classified Instances
                                       110
                                                         96.4912 %
                                                          3.5088 %
Incorrectly Classified Instances
Kappa statistic
                                         0.923
Mean absolute error
                                         0.0562
                                         0.1738
Root mean squared error
Relative absolute error
Root relative squared error
                                        36.3571 %
Total Number of Instances
=== Detailed Accuracy By Class ===
                 TP Rate FP Rate Precision Recall F-Measure MCC
                                                                            ROC Area PRC Area Class
                 0.950 0.027 0.950 0.950 0.950 0.923
0.973 0.050 0.973 0.973 0.973 0.923
                                                                           0.983 0.975
0.983 0.982
                                                                                                В
Weighted Avg.
                0.965 0.042 0.965
                                                       0.965
                                                                 0.923
                                             0.965
                                                                           0.983
                                                                                     0.980
=== Confusion Matrix ===
 a b <-- classified as
38 2 | a = M
2 72 | b = B
```

Precision bernilai 0.965, Recall bernilai 0.965, dan F-Measure bernilai 0.965

b. Supplied test set WDBC-testing.arff pada k = 5

```
=== Summary ===
Correctly Classified Instances
Incorrectly Classified Instances
                                                                        2.6316 %
Kappa statistic
                                                  0.0495
Mean absolute error
Root mean squared error
                                                   0.1402
Relative absolute error
                                                  10.6772 %
Root relative squared error
                                                  29.3291 %
Total Number of Instances
                                                114
=== Detailed Accuracy By Class ===
TP Rate FP Rate Precision Recall F-Measure MCC ROC Area PRC Area Class 0.975 0.027 0.951 0.975 0.963 0.943 0.997 0.993 M 0.973 0.025 0.986 0.973 0.980 0.943 0.997 0.998 B Weighted Avg. 0.974 0.026 0.974 0.974 0.974 0.943 0.997 0.996
=== Confusion Matrix ===
  a b <-- classified as
  2 72 | b = B
```

Precision bernilai 0.974, Recall bernilai 0.974, dan F-Measure bernilai 0.974

c. Supplied test set WDBC-testing.arff pada k = 7

```
=== Summary ===
Correctly Classified Instances
                                                                      99.1228 %
                                              1
0.9809
Incorrectly Classified Instances
                                                                       0.8772 %
Kappa statistic
Mean absolute error
                                                 0.0529
Root mean squared error
                                                 0.1311
                                                11.4089 %
27.4322 %
Relative absolute error
Root relative squared error
                                               114
Total Number of Instances
=== Detailed Accuracy By Class ===
                  TP Rate FP Rate Precision Recall F-Measure MCC ROC Area PRC Area Class
1.000 0.014 0.976 1.000 0.988 0.981 0.999 0.998 M
0.986 0.000 1.000 0.986 0.993 0.981 0.999 0.999 B
0.991 0.005 0.991 0.991 0.991 0.981 0.999 0.999
Weighted Avg.
=== Confusion Matrix ===
          <-- classified as
 40 0 | a = M
  1 73 | b = B
```

Precision bernilai 0.991, Recall bernilai 0.991, dan F-Measure bernilai 0.991.

#### d. Supplied test set WDBC-testing.arff pada k = 9

```
Correctly Classified Instances
                                                              99.1228 %
Incorrectly Classified Instances
Kappa statistic
                                            0.9809
Mean absolute error
                                            0.0616
Root mean squared error
Relative absolute error
                                           13.286 %
Root relative squared error
                                           28.9701 %
Total Number of Instances
=== Detailed Accuracy By Class ===
                  TP Rate FP Rate Precision Recall
                                                           F-Measure MCC
                                                                                 ROC Area PRC Area Class
                1.000 0.014 0.976
0.986 0.000 1.000
0.991 0.005 0.991
                                                 1.000 0.988 0.981 0.999
0.986 0.993 0.981 0.999
0.991 0.991 0.981 0.999
                                                                                            0.999
                                                                                                      В
Weighted Avg.
                                                                                            0.999
=== Confusion Matrix ===
  a b <-- classified as
  1 73 | b = B
```

Precision bernilai 0.991, Recall bernilai 0.991, dan F-Measure bernilai 0.991.

e. Supplied test set WDBC-testing.arff pada k = 11

```
=== summary ===
 Correctly Classified Instances
  Incorrectly Classified Instances
                                                                                                                                                                                                                                                                      1.7544 %
                                                                                                                                                                                        0.961
 Kappa statistic
 Mean absolute error
  Root mean squared error
                                                                                                                                                                                      0.1473
 Relative absolute error
                                                                                                                                                                                 14.6526 %
  Root relative squared error
                                                                                                                                                                                      30.8048 %
 Total Number of Instances
  === Detailed Accuracy By Class ===
                                                                             TP Rate FP Rate Precision Recall F-Measure MCC
                                                                                                                                                                                                                                                                                                                                                    ROC Area PRC Area Class
                                                                            1. Add 1.
                                                                                                                                                                                                                                                       0.974
                                                                                                                                                                                                                                                                                                          0.962
                                                                                                                                                                                                                                                                                                          0.962 0.999
                                                                                                                                                                                                                                                                                                                                                                                                0.999
                                                                                                                                                                                                                                                                                                                                                                                                                                              В
  Weighted Avg. 0.982
                                                                                                                                                                                                                                                       0.982
                                                                                                                                                                                                                                                                                                          0.962
                                                                                                                                                                                                                                                                                                                                                 0.999
                                                                                                                                                                                                                                                                                                                                                                                                0.999
  === Confusion Matrix ===
                                    <-- classified as
     38 2 | a = M
```

Precision bernilai 0.982, Recall bernilai 0.982, dan F-Measure bernilai 0.982.

f. Cross-validation dengan file WDBC.arff pada k = 3

```
=== Summary ===
Correctly Classified Instances
                                                            96.8366 %
Incorrectly Classified Instances
                                         18
                                                             3.1634 %
Kappa statistic
                                           0.9318
Mean absolute error
                                          0.0487
                                           0.1711
Root mean squared error
Relative absolute error
                                         10.4128 %
Root relative squared error
                                          35.3883 %
Total Number of Instances
=== Detailed Accuracy By Class ===
                  TP Rate FP Rate Precision Recall
                                                         F-Measure MCC
                                                                               ROC Area PRC Area Class
0.939 0.014 0.975 0.939 0.957 0.932

0.986 0.061 0.964 0.986 0.975 0.932

Weighted Avg. 0.968 0.044 0.969 0.968 0.968 0.932
                                                                             0.980 0.973 M
                                                                             0.980
                                                                                         0.978
                                                                                         0.976
=== Confusion Matrix ===
   a b <-- classified as
199 13 | a = M
5 352 | b = B
```

Precision bernilai 0.969, Recall bernilai 0.968, dan F-Measure bernilai 0.968.

g. Cross-validation dengan file WDBC.arff pada k = 5

```
=== Stratified cross-validation ===
=== Summary
                                                         97.0123 %
Correctly Classified Instances
Incorrectly Classified Instances
Kappa statistic
                                         0.9355
Mean absolute error
Root mean squared error
                                        0.1621
Relative absolute error
                                       10.7568 %
Root relative squared error
                                        33.5346 %
Total Number of Instances
                                       569
=== Detailed Accuracy By Class ===
                 TP Rate FP Rate Precision Recall
                                                                           ROC Area PRC Area Class
                 0.939 0.011 0.980 0.939 0.959 0.936 0.987 0.982
0.989 0.061 0.964 0.989 0.976 0.936 0.987 0.987
Weighted Avg.
                0.970 0.043 0.970
                                              0.970
                                                     0.970
                                                                  0.936 0.987
                                                                                     0.985
=== Confusion Matrix ===
   a b <-- classified as
199 13 | a = M
4 353 | b = B
```

Precision bernilai 0.970, Recall bernilai 0.970, dan F-Measure bernilai 0.970

h. Cross-validation dengan file WDBC.arff pada k = 7

```
=== Summary ===
Correctly Classified Instances
Incorrectly Classified Instances
                                         16
                                                             2.812 %
                                           0.9394
Kappa statistic
Mean absolute error
Root mean squared error
                                           0.1639
Relative absolute error
                                         12.1383 %
Root relative squared error
Total Number of Instances
                                         33.9003 %
                                        569
=== Detailed Accuracy By Class ===
                 TP Rate FP Rate Precision Recall F-Measure MCC
                                                                             ROC Area PRC Area Class
                                                        0.962 0.940
                 0.943 0.011 0.980 0.943
0.989 0.057 0.967 0.989
                                                                             0.989
                                                                                        0.983
                                                                                                   M
Weighted Avg.
                0.972
                         0.040
                                   0.972
                                             0.972
                                                        0.972
                                                                   0.940
                                                                             0.989
                                                                                        0.987
 === Confusion Matrix ===
 a b <-- classified as
200 12 | a = M
4 353 | b = B
```

Precision bernilai 0.927, Recall bernilai 0.972, dan F-Measure bernilai 0.972

i. Cross-validation dengan file WDBC.arff pada k = 9

```
=== summary ===
Correctly Classified Instances
Incorrectly Classified Instances
                                                               2.812 %
                                            0.9392
Kappa statistic
Mean absolute error
                                            0.0611
Root mean squared error
                                            0.1643
Relative absolute error
Root relative squared error
Total Number of Instances
                                           33.9814 %
=== Detailed Accuracy By Class ===
                  TP Rate FP Rate Precision Recall F-Measure MCC
                                                                                 ROC Area PRC Area Class
                0.934 0.006 0.990 0.934
0.994 0.066 0.962 0.994
0.972 0.044 0.972 0.972
                                                            0.961
                                                                       0.940
                                                                                 0.991
                                                                                             0.989
                                                           0.978
                                                                       0.940
                                                                                 0.991
                                                                                            0.991
   a b <-- classified as
198 14 | a = M
2 355 | b = B
```

Precision bernilai 0.927, Recall bernilai 0.972, dan F-Measure bernilai 0.972

j. Cross-validation dengan file WDBC.arff pada k = 11

```
=== Summary ===
                                                                96.6608 %
Correctly Classified Instances
                                            550
                                                                 3.3392 %
Incorrectly Classified Instances
                                            19
Kappa statistic
                                              0.9278
Mean absolute error
                                             0.067
Root mean squared error
                                             0.1722
Relative absolute error
                                            14.3168 %
Total Number of Instances
                                           569
=== Detailed Accuracy By Class ===
                                                                                   ROC Area PRC Area Class
                   TP Rate FP Rate Precision Recall
                                                             F-Measure MCC
0.929 0.011 0.980 0.929 0.954 0.929 0.990 0.987
0.989 0.071 0.959 0.989 0.974 0.929 0.990 0.990
Weighted Avg. 0.967 0.049 0.967 0.966 0.929 0.990 0.989
=== Confusion Matrix ===
       b <-- classified as
 197 15 | a = M
4 353 | b = B
```

Precision bernilai 0.967, Recall bernilai 0.967 dan F-Measure bernilai 0.966

#### 3. Kesimpulan

Precision terbesar yang di dapat dari uji coba adalah pada supplied test set dengan k=7 dan k=9 berada pada angka 0.991. Recall terbesar yang di dapat dari uji coba adalah pada supplied test set dengan k=7 dan k=9 berada pada angka 0.991. F-Measure terbesar yang di dapat dari uji coba adalah pada supplied test set dengan k=7 dan k=9 berada pada angka 0.991. Pada kasus dataset WDBC, menggunakan ke-5 k menunjukkan pengujian supplied test dapat menghasilkan akurasi yang lebih baik daripada cross-validation, selain itu dari ke-5 k menunjukkan penggunaan k=7 dan k=9 lebih baik digunakan untuk dataset ini.

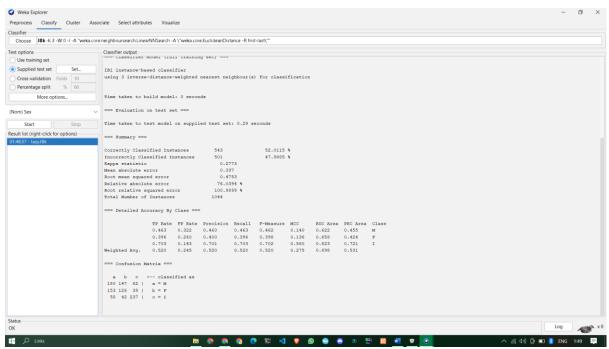
#### B. Abalone

- Tools yang digunakan adalah WEKA explorer
- 1. Langkah-langkah untuk memisahkan data Abalone
- Buka WEKA Explorer dan buka file Abalone.arff.
- Kemudian pada bagian filter pilih Randomize pada package weka => filters => unsupervised=>instance => Randomize.
- Tanpa melakukan konfigurasi tambahan maka dataset tersebut telah teracak.
- Selanjutnya Kembali ke bagian filter pilih RemovePercentage pada package weka
   => filters =>unsupervised => instance => RemovePercentage.
- Pada bagian tersebut mengantikan presentase menjadi 75.0 untuk data testing maka data terhapus sebanyak 75 persen.
- Selanjutnya tekan apply dan simpan data tersebut dengan menekan save as di WEKA menjadi Abalone-testing.arrf.

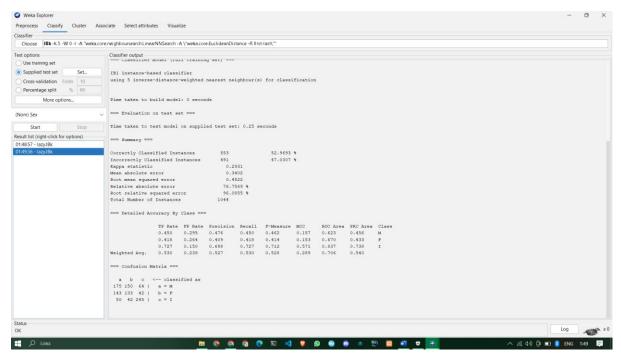
- Kembali ke halaman utama weka dan klik undo, selanjutnya ganti nilai invertSelection menjadi True, dengan percentage masih sama maka data tersimpan sebanyak 75 persen.
- 2. Uraikan hasil klasifikasi yang diperoleh.

Proses klasifikasi menggunakan Classifier IBk (Lazy/KNN) dengan k=3, k=5, k=7, k=9,dan k=11 serta pembobotan dalam voting penentuan class adalah distanceWeighting =Weight by 1/distance.

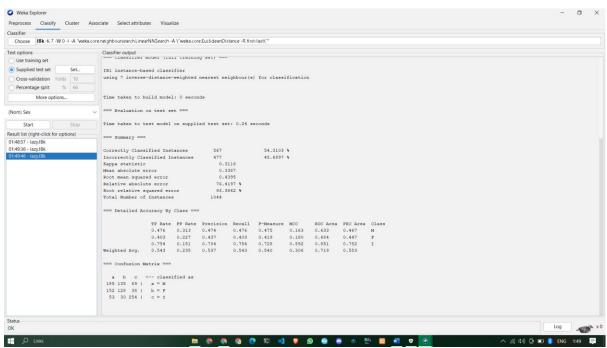
a. Supplied test set Abalone-testing.arff pada k = 3



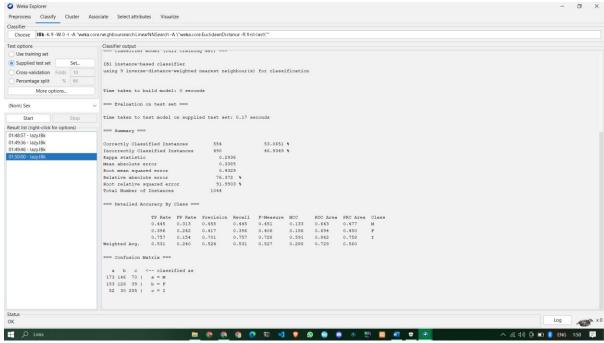
b. Supplied test set Abalone-testing.arff pada k = 5



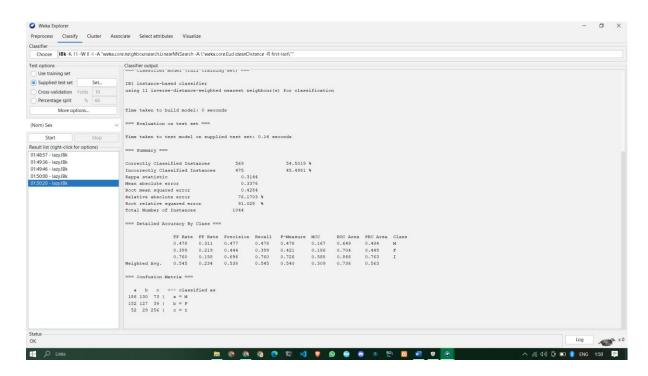
c. Supplied test set Abalone-testing.arff pada k = 7



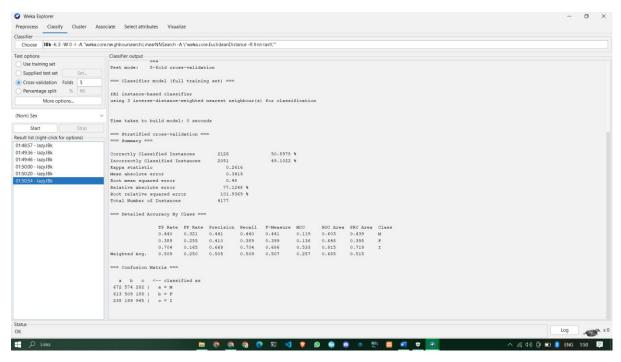
d. Supplied test set Abalone-testing.arff pada k = 9



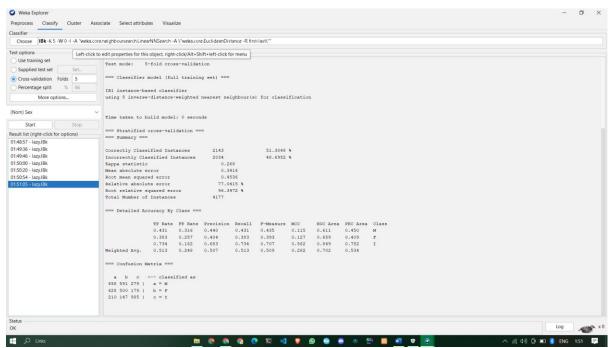
e. Supplied test set Abalone-testing.arff pada k = 11



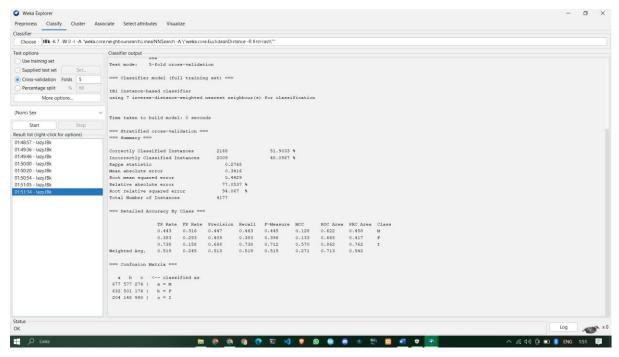
f. Cross-validation dengan file Abalone.arff pada k = 3



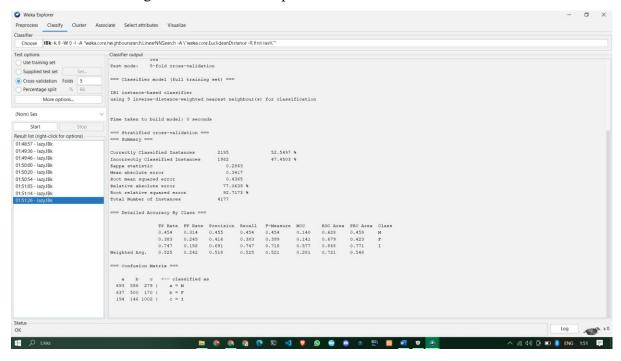
g. Cross-validation dengan file Abalone.arff pada k = 5



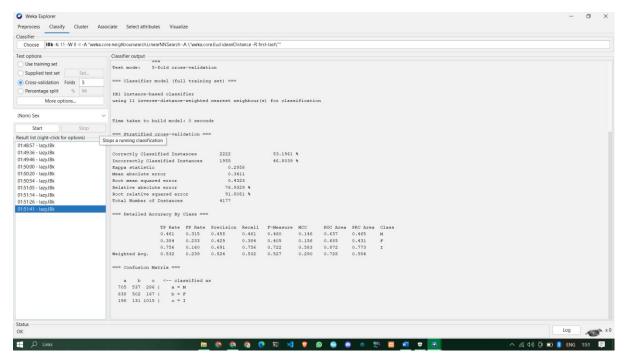
h. Cross-validation dengan file Abalone.arff pada k = 7



i. Cross-validation dengan file Abalone.arff pada k = 9



j. Cross-validation dengan file Abalone.arff pada k = 11



#### 3. Kesimpulan.

Precision terbesar yang di dapat dari uji coba adalah pada supplied test set dengan k=7 berada pada angka 0.537. Recall terbesar yang di dapat dari uji coba adalah pada supplied test set dengan k=11 berada pada angka 0.545. F-Measure terbesar yang di dapat dari uji coba adalah pada supplied test set dengan k=7 dan k=11 berada pada angka 0.540. Pada kasus dataset Abalone, menggunakan ke-5 k menunjukkan pengujian supplied test dapat menghasilkan akurasi yang lebih baik daripada cross-validation, selain itu dari ke-5 k menunjukkan penggunaan k=7 dan k=11 lebih baik digunakan untuk dataset ini.

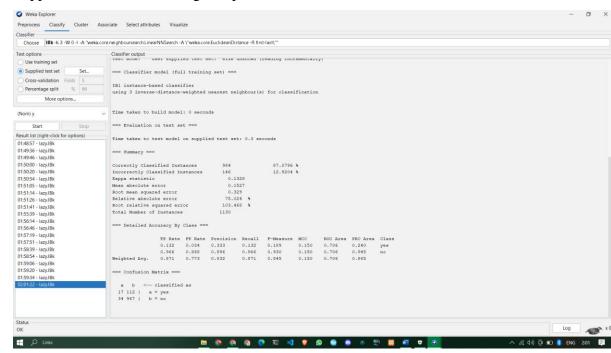
#### C. Bank Data

- 1. Langkah-langkah untuk memisahkan data Bank.
- Buka WEKA Explorer dan buka file Bank.arff.
- Kemudian pada bagian filter pilih Randomize pada package weka => filters => unsupervised=>instance => Randomize.
- Tanpa melakukan konfigurasi tambahan maka dataset tersebut telah teracak.
- Selanjutnya Kembali ke bagian filter pilih RemovePercentage pada package weka
   => filters =>unsupervised => instance => RemovePercentage.
- Pada bagian tersebut mengantikan presentase menjadi 75.0 untuk data testing maka data terhapus sebanyak 75 persen.
- Selanjutnya tekan apply dan simpan data tersebut dengan menekan save as di WEKA menjadi bank-testing.arrf.

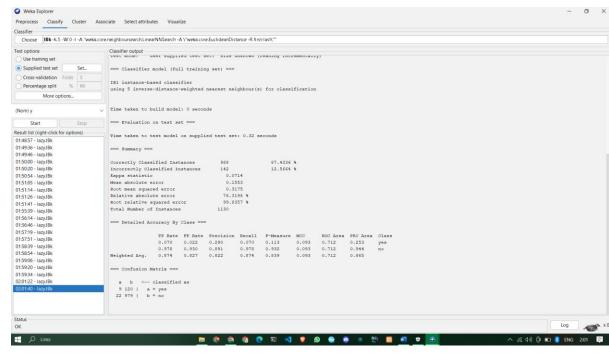
- Kembali ke halaman utama weka dan klik undo, selanjutnya ganti nilai invertSelection menjadi True, dengan percentage masih sama maka data tersimpan sebanyak 75 persen.
- 2. Uraikan hasil klasifikasi yang diperoleh.

Proses klasifikasi menggunakan Classifier IBk (Lazy/KNN) dengan k=3, k=5, k=7, k=9,dan k=11 serta pembobotan dalam voting penentuan class adalah distanceWeighting =Weight by 1/distance.

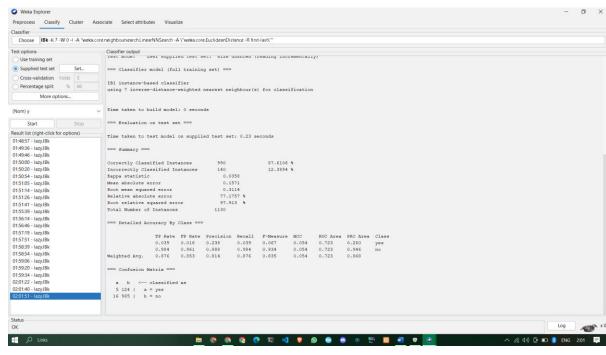
a. Supplied test set bank-testing.arff pada k = 3



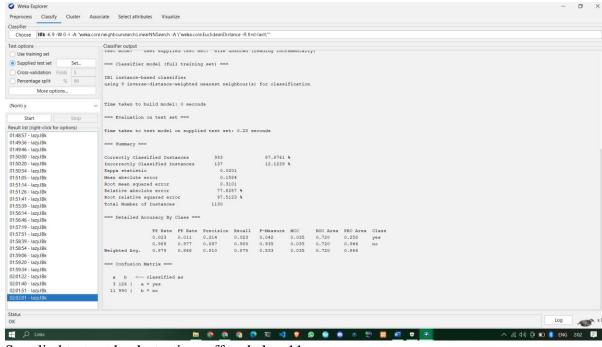
b. Supplied test set bank-testing.arff pada k = 5



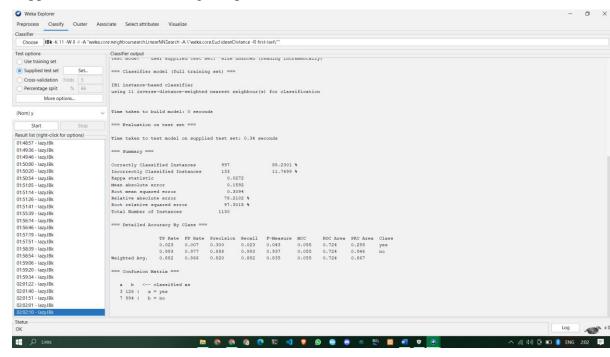
c. Supplied test set bank-testing.arff pada k = 7



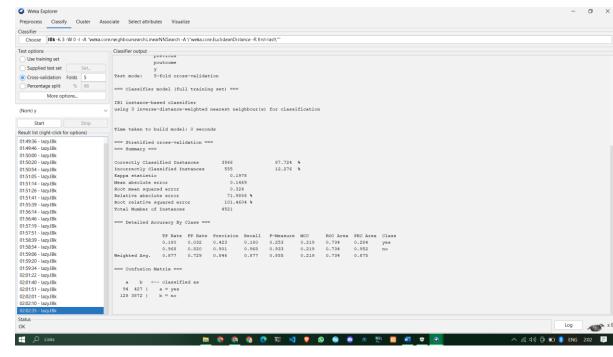
d. Supplied test set bank-testing.arff pada k = 9



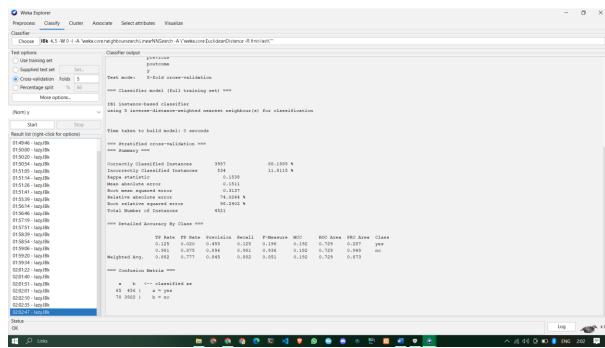
e. Supplied test set bank -testing.arff pada k = 11



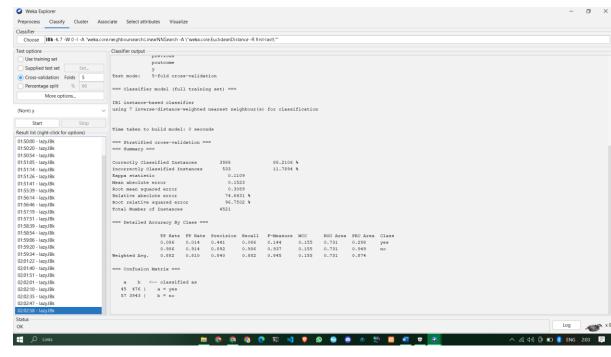
f. Cross-validation dengan file bank.arff pada k = 3



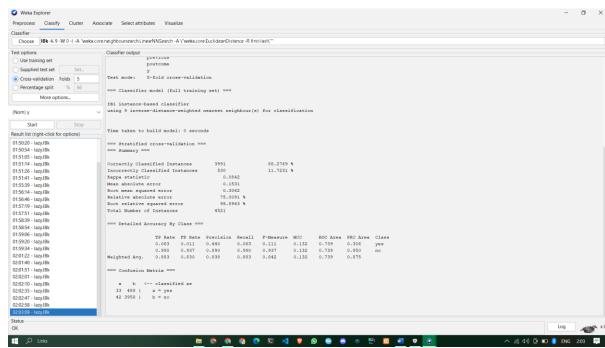
g. Cross-validation dengan file bank.arff pada k = 5



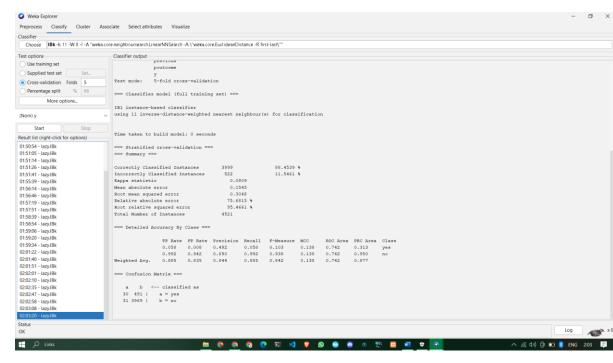
h. Cross-validation dengan file bank.arff pada k = 7



i. Cross-validation dengan file bank.arff pada k = 9



j. Cross-validation dengan file bank.arff pada k = 11



#### 3. Kesimpulan.

Precision terbesar yang di dapat dari uji coba adalah pada supplied test set dengan k=3 berada pada angka 0.832. Recall terbesar yang di dapat dari uji coba adalah pada crossvalidation dengan k=11 berada pada angka 0.885. F-Measure terbesar yang di dapat dari uji coba adalah pada supplied test set dengan k=3 berada pada angka 0.845. Pada kasus dataset Bank Marketing, menggunakan ke-5 k menunjukkan hasil pengujian yang tidak memiliki selisih yang cukup besar baik pada pengujian supplied test maupun crossvalidation. Nilai k yang digunakan pada supplied test lebih baik digunakan pada k=3, lebih dari itu menghasilkan akurasi yang lebih rendah, namun pada cross-validation cenderung lebih baik menggunakan k yang lebih besar seperti 11.

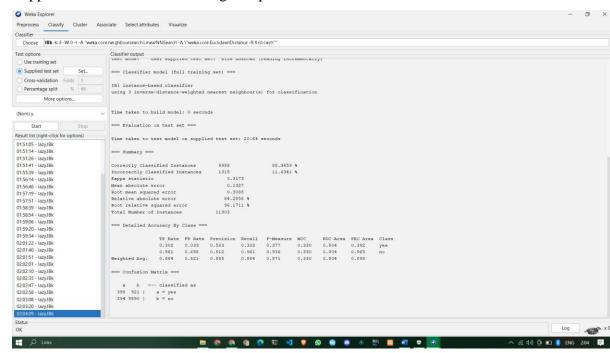
#### D. Bank-full

- 1. Langkah-langkah untuk memisahkan data Bank-full.
- Buka WEKA Explorer dan buka file Bank-full.arff.
- Kemudian pada bagian filter pilih Randomize pada package weka => filters => unsupervised=>instance => Randomize.
- Tanpa melakukan konfigurasi tambahan maka dataset tersebut telah teracak.
- Selanjutnya Kembali ke bagian filter pilih RemovePercentage pada package weka
   => filters =>unsupervised => instance => RemovePercentage.
- Pada bagian tersebut mengantikan presentase menjadi 75.0 untuk data testing maka data terhapus sebanyak 75 persen.

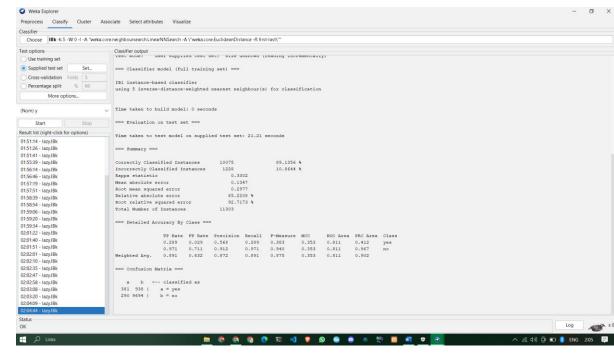
- Selanjutnya tekan apply dan simpan data tersebut dengan menekan save as di WEKA menjadi bank-full-testing.arrf.
- Kembali ke halaman utama weka dan klik undo, selanjutnya ganti nilai invertSelection menjadi True, dengan percentage masih sama maka data tersimpan sebanyak 75 persen.
- 2. Uraikan hasil klasifikasi yang diperoleh.

Proses klasifikasi menggunakan Classifier IBk (Lazy/KNN) dengan k=3, k=5, k=7, k=9,dan k=11 serta pembobotan dalam voting penentuan class adalah distanceWeighting =Weight by 1/distance.

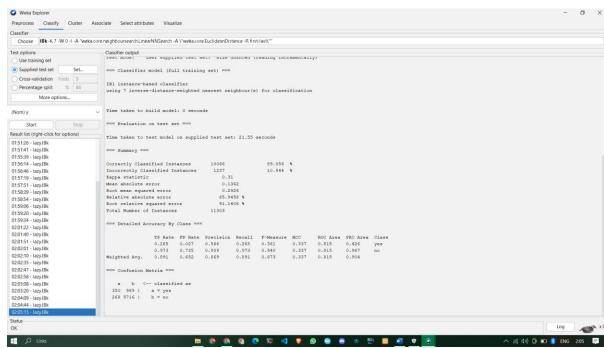
a. Supplied test set bank-full-testing.arff pada k = 3



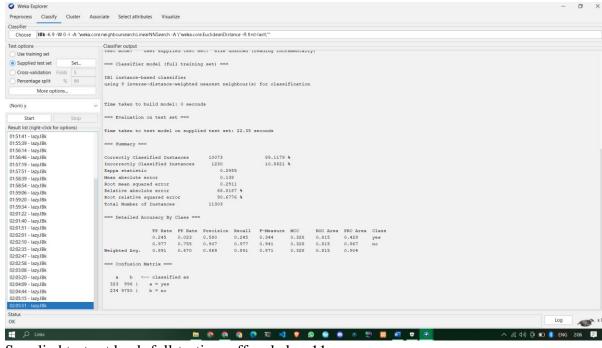
b. Supplied test set bank-full-testing.arff pada k = 5



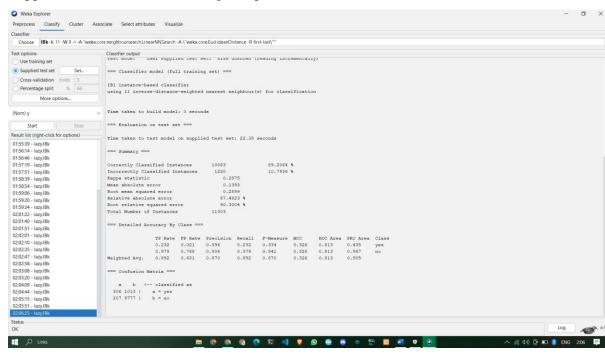
c. Supplied test set bank-full-testing.arff pada k = 7



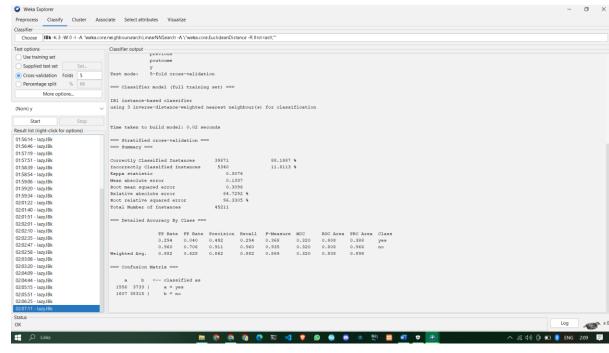
d. Supplied test set bank-full-testing.arff pada k = 9



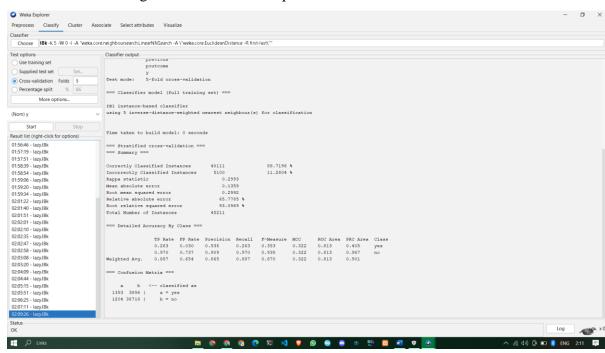
e. Supplied test set bank-full-testing.arff pada k = 11



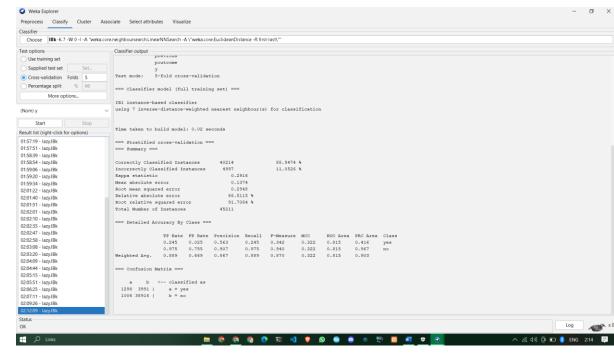
f. Cross-validation dengan file bank-full.arff pada k = 3



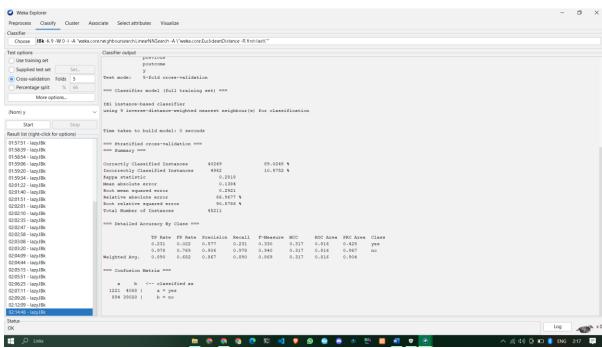
g. Cross-validation dengan file bank-full.arff pada k = 5



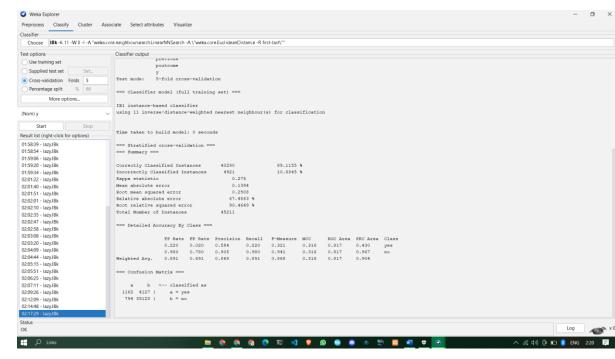
h. Cross-validation dengan file bank-full.arff pada k = 7



i. Cross-validation dengan file bank-full.arff pada k = 9



j. Cross-validation dengan file bank-full.arff pada k = 11



#### 3. Kesimpulan.

Precision terbesar yang di dapat dari uji coba adalah pada supplied test set dengan k=5 berada pada angka 0.872. Recall terbesar yang di dapat dari uji coba adalah pada crossvalidation dengan k=11 berada pada angka 0.892. F-Measure terbesar yang di dapat dari uji coba adalah pada supplied test set dengan k=5 berada pada angka 0.875. Pada kasus dataset Bank Marketing, menggunakan ke-5 k menunjukkan hasil pengujian yang tidak memiliki selisih yang cukup besar baik pada pengujian supplied test maupun crossvalidation. Nilai k yang digunakan pada supplied test lebih baik digunakan pada k=5, lebih dari itu menghasilkan akurasi yang lebih rendah, namun pada cross-validation cenderung lebih baik menggunakan k yang lebih besar seperti 9 atau 11.